

Entrega Final

Nicolás Delgado y Fabián Díaz

15-12-2021

Ajustes previos

```
library("readr")
library("car")
library("dplyr")
library("texreg")
library("lme4")
library("ggplot2")
library("lattice")
library("tidyverse")
library("panelr")
library("plm")
library("GLMMadaptive")
library("prediction")
library("margins")
library("tinytex")
library("vcd")
library("vcdExtra")

path <- url("https://raw.githubusercontent.com/mebucca/cda_soc3070/master/homework/tf/redcard_data.csv")
data_redcards <- read.csv(path)
```

Desarrollo

1. Variables de interés focal

El presente trabajo se centrará en la relación entre recibir una tarjeta roja en un partido y el color de piel del jugador. Para esto, la variable dependiente será medida a partir de una dummy que toma valor 1 cuando un jugador recibe una tarjeta roja de parte de un árbitro y 0 en el caso contrario. Por su parte, la variable independiente será medida a partir de una escala de 5 puntos que van desde “piel muy clara” (0) a “piel muy oscura” (1), con “piel ni oscura ni clara” como valor central (0.5).

En vista de esto, recodificamos las variables de la siguiente manera:

#Variable dependiente.

```
data_redcards$red <- ifelse(data_redcards$redCards=='0',0,1)
data_redcards$red <- factor(data_redcards$red)
```

#Variable independiente.

```
data_redcards$rater1 <- factor(data_redcards$rater1)
```

Dado que no todos los jugadores tienen valores para la variable independiente de interés, se tomó la decisión de eliminar aquellas filas con valores NA.

```
data_redcards <- na.omit(data_redcards)
```

A continuación, para ver si tiene sentido analizar ambas variables, hacemos un test Chi-cuadrado de Independencia con las siguientes condiciones:

- H_0 : Escala color de piel y obtener una tarjeta roja son independientes
- H_1 : Escala color de piel y obtener una tarjeta roja son dependientes
- $\alpha = 0.05$

En R,

#Test de Chi-cuadrado

```
chisq.test(data_redcards$rater1, data_redcards$red)
```

```
##
```

```
## Pearson's Chi-squared test
```

```
##
```

```
## data: data_redcards$rater1 and data_redcards$red
```

```
## X-squared = 12.399, df = 4, p-value = 0.01462
```

Dado que el valor-p es menor al nivel de significancia establecido previamente, hay suficiente evidencia estadística para rechazar la hipótesis nula; es decir, ambas variables están asociadas.

2. Pregunta de investigación

El presente trabajo busca abordar la relación entre las variables a partir de una pregunta de tipo 2 (Auspurg y Brüderl, 2021). Específicamente, la pregunta es: ¿tiene el color de piel de los jugadores un efecto sobre la probabilidad de obtener una tarjeta roja?

3. Variables de control

Sin embargo, el efecto de esta variable puede estar siendo explicado por otras no observadas por el modelo estimado. Con el fin de abordar esta posibilidad, se incorporan al modelo dos variables de control (por instrucción de simplicidad). Estas corresponden a:

- Posición del jugador [position]: dependiendo del rol que el jugador cumpla para su equipo estará más expuesto a cometer infracciones (defensas o mediocampistas), lo que afecta en la probabilidad de recibir una tarjeta roja.
- Sesgo racial explícito en país del árbitro [meanExp]: El sesgo racial explícito moderará el efecto del color de piel sobre la probabilidad de que un jugador obtenga una tarjeta roja.

3.1 Justificación variables de control

Posición

Como se justificó arriba, la posición de un jugador en la cancha se relaciona a la probabilidad de obtener tarjetas rojas. Esto se debe a que la estrategia utilizada por los jugadores en cancha, así como las instrucciones dadas a cada uno, varían según su posición. Los volantes de corte y los defensas tienen mayor probabilidad de cometer faltas que los delanteros, dado que los primeros deben lograr detener al jugador contrario. Esto se plasma en la cultura popular, donde un dicho común empleado por los entrenadores a los jugadores en posiciones de defensa es “o pasa el balón, o el jugador; pero no los dos”.

Dado esto, se esperaría que la posición del jugador tenga un efecto sobre la probabilidad de obtener tarjeta roja, siendo mayor en el caso de los defensas y centro campista. Para incorporar esta variable en el modelo, se recodificó la variable *position* en cuatro categorías (arquero, defensa, centrocampista, delantero), siendo la categoría de referencia delantero.

```
data_redcards$position<-factor(data_redcards$position)
data_redcards$position<-as.numeric(data_redcards$position)

data_redcards$pos<- car::recode(data_redcards$position,
                                "6=4; 7=2;10=2;2=2; 1=3; 4=3; 5=3; 8=3;
                                11=3; 3=1; 9=1; 12=1")

data_redcards$pos<- factor(data_redcards$pos,
                            levels=c(1,2,3,4) ,
                            labels = c("Delantero", "Defensa", "Centrocampista","Arquero"))
```

Para evaluar si tiene sentido ocupar esta variable como control, deberíamos esperar que esté relacionada con la variable dependiente. Para comprobarlo, nuevamente hacemos un test de Chi-cuadrado de Independencia con las siguientes condiciones:

- H_0 : La posición de un jugador en cancha y obtener una tarjeta roja son independientes
- H_1 : La posición de un jugador en cancha y obtener una tarjeta roja son dependientes
- $\alpha = 0.05$

En R,

```
chisq.test(data_redcards$pos, data_redcards$red)

##
## Pearson's Chi-squared test
##
## data: data_redcards$pos and data_redcards$red
## X-squared = 71.815, df = 3, p-value = 1.744e-15
```

Como el valor-p es menor al nivel de significancia establecido previamente, hay suficiente evidencia estadística para rechazar la hipótesis que ambas variables son independientes. Por tanto, hay una asociación entre la posición en cancha y si es que el jugador obtuvo una roja.

Sesgo racial explícito del país de origen

El sesgo racial del país de origen puede tener un efecto sobre la probabilidad de tener una tarjeta roja. Esto se debe a que nuestra variable dependiente está asociada al árbitro que toma la decisión de amonestar de esa forma al jugador. En este sentido, el sesgo racial del país de origen del árbitro

puede tener un efecto en la decisión de amonestar a un jugador por su color de piel. En este sentido, también puede moderar el efecto del color de piel del jugador sobre la probabilidad de ser amonestado con una tarjeta roja.

Ahora bien, se toma la decisión de incorporar esta variable en lugar de sesgo racial implícito, dado que el sesgo racial explícito considera la demostración frente a otro de un comportamiento o actitud racista. De esta forma, dado que poner una tarjeta roja es una manifestación explícita -de cara a un público-, se esperaría que esta variable sea más acorde al tipo de variable del modelo.

Sin embargo, ambos indicadores presentan una alta correlación de Pearson.

```
cor(data_redcards$meanExp, data_redcards$meanIAT)
```

```
## [1] 0.7649808
```

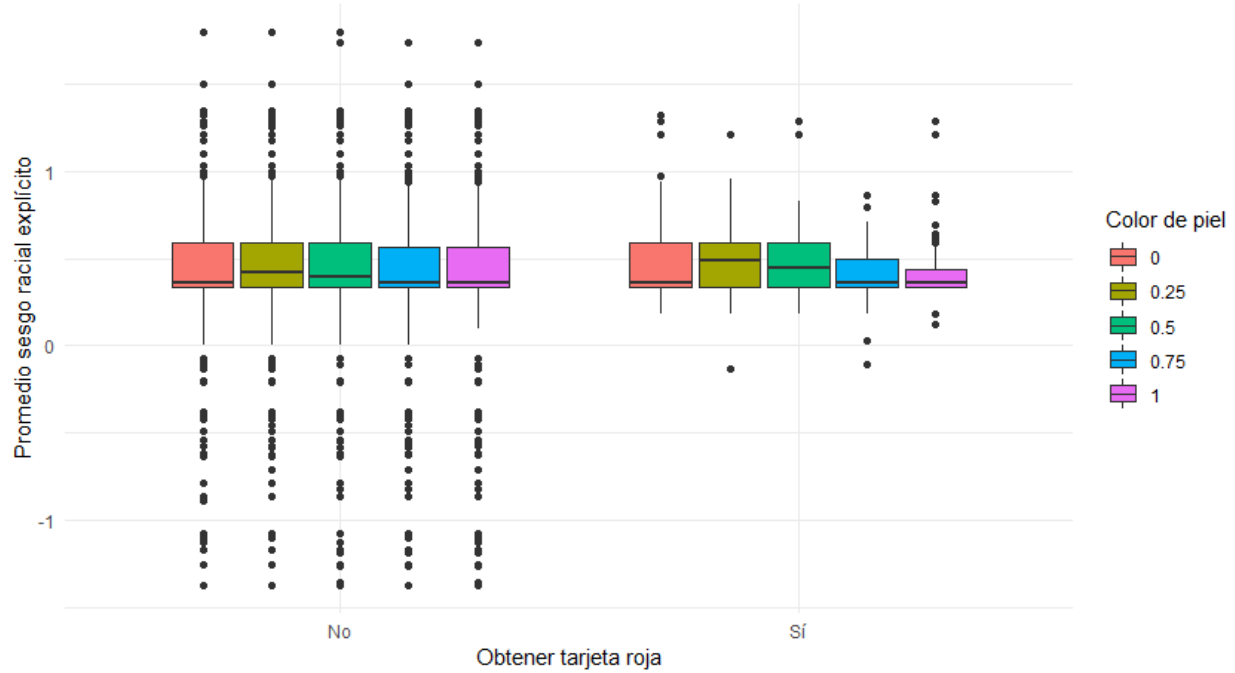
Por tanto, no debiera haber mayor variación; por lo que utilizaremos el explícito por los motivos esgrimidos anteriormente. Aun así, utilizaremos el implícito para posteriores análisis de robustez.

4. Modelo de regresión

A partir de la selección de los controles, esperaríamos que el color de piel y la posición del jugador tengan un efecto lineal con la variable dependiente. Sin embargo, como se mencionó más arriba, la variable de racismo explícito puede moderar el efecto del color de piel del jugador sobre la probabilidad de ser amonestado con una tarjeta roja. Para explorar este supuesto, se realizó un boxplot entre las tres variables, que se muestra a continuación.

```
ggplot(data_redcards, aes(x=red, fill=rater1)) +  
  labs(title="Fig 1. Tarjetas rojas y sesgo racial explícito por color de piel",  
        caption="Fuente: Elaboración propia en base a datos facilitados",  
        x="Obtener tarjeta roja", y = "Promedio sesgo racial explícito") +  
  geom_boxplot(aes(y=meanExp, fill=rater1)) +  
  scale_x_discrete(labels=c("No", "Sí")) +  
  scale_fill_discrete(name="Color de piel") +  
  theme_minimal()
```

Fig 1. Tarjetas rojas y sesgo racial explícito por color de piel



Al ver el cuadrante derecho, observamos que existe un menor solapamiento entre las diferentes cajas. Más aún, vemos que las categorías 0.75 y 1 (piel más oscura) se comportan distinto respecto a las categorías de piel más clara.

Por tanto, la forma funcional del modelo que queremos estimar es el siguiente

$$f(red_i) = \beta_0 + \beta_1 * rater1_i + \beta_2 * position_i + \beta_3 * meanExp_i + \beta_4 * rater1_i * meanExp_i$$

4.1 Tipo de modelo

Por la forma en que está definida la variable dependiente, un jugador puede obtenerse solo una tarjeta roja por partido de fútbol. En este sentido, el jugador tuvo o no tuvo una tarjeta roja. Así, la obtención de una tarjeta roja puede pensarse como una variable binomial, cuyo resultado proviene del “experimento” de que un jugador con cierto color de piel y posición al jugar un partido con un árbitro cuyo país tiene cierto nivel de racismo explícito obtenga una tarjeta roja. En este sentido, la distribución de esta variable tendría una distribución Binomial; por ende, la función de enlace para nuestro modelo es logit, con $\eta = \ln(\frac{p_i}{1-p_i})$, siendo $\eta = f(red_i)$. Es decir:

$$logit(red_i) = \ln(\frac{p_i}{1-p_i}) = \beta_0 + \beta_1 * rater1_i + \beta_2 * position_i + \beta_3 * meanExp_i + \beta_4 * rater1_i * meanExp_i$$

Con,

$$red_i \sim Bernoulli(p_i = \frac{e^{\eta_i}}{1 + e^{\eta_i}})$$

$p_i \rightarrow$ la probabilidad del jugador i de tener una roja.

5. Ajuste del modelo

```

modelo_1 <- glm(red ~ rater1, family=binomial(link="logit"), data=data_redcards)

modelo_2 <- glm(red ~ rater1+pos, family=binomial(link="logit"), data=data_redcards)

modelo_3 <- glm(red ~ rater1+pos+meanExp, family=binomial(link="logit"), data=data_redcards)

modelo_4 <- glm(red ~ rater1*meanExp+pos, family=binomial(link="logit"), data=data_redcards)

texreg(list( modelo_1, modelo_2, modelo_3, modelo_4),
        caption="Tabla 1: Modelos de regresión logística",
        digits=4)

```

Tabla 1: Modelos de regresión logística

	Modelo 1	Modelo 2	Modelo 3	Modelo 4
Intercepto	−4.4786*** (0.0440)	−4.7063*** (0.0732)	−4.6260*** (0.0923)	−4.5252*** (0.1264)
Color de piel 0.25	0.1825** (0.0617)	0.1872** (0.0617)	0.1903** (0.0618)	0.0649 (0.1558)
Color de piel 0.5	0.1696 (0.0897)	0.1584 (0.0903)	0.1595 (0.0903)	−0.1554 (0.2189)
Color de piel 0.75	0.2072* (0.1022)	0.2443* (0.1032)	0.2375* (0.1033)	0.1967 (0.1984)
Color de piel 1	0.2415* (0.1073)	0.2828** (0.1082)	0.2753* (0.1084)	0.1433 (0.2016)
Defensa		0.4939*** (0.0737)	0.4921*** (0.0737)	0.4916*** (0.0737)
Centrocampista		0.0333 (0.0790)	0.0312 (0.0790)	0.0304 (0.0791)
Arquero		0.2565* (0.1066)	0.2514* (0.1067)	0.2501* (0.1067)
Racismo explícito			−0.1703 (0.1201)	−0.3918 (0.2273)
Color 0.25:Rac. exp				0.2747 (0.3099)
Color 0.5:Rac. exp				0.6726 (0.4191)
Color 0.75:Rac. exp				0.0770 (0.4025)
Color 1:Rac. exp				0.2978 (0.3971)
Num. obs.	115457	115457	115457	115457

***p < 0.001; **p < 0.01; *p < 0.

La Tabla 1 resume los resultados relevantes obtenidos. Se estimaron cuatro modelos, donde el primero de ellos solo incluye la variable de interés, mientras que en los otros se agregan las variables de control y el efecto de interacción, respectivamente. En base a esto, se puede observar en el modelo 1, que, en relación con la categoría de referencia, el efecto de color de piel sobre el logit de la odds de recibir una tarjeta roja es significativo para todas las categorías, excepto para los de piel ni oscura ni clara (0.5). En este sentido, el color de piel tiene un efecto sobre el logit de las odds de recibir una tarjeta roja. Al agregar la variable de control posición de juego al modelo, observamos que la significancia de la variables de interés aumenta en la categoría de piel más oscura (1), manteniéndose constante para el resto de las categorías. Lo mismo ocurre al incorporar al modelo la segunda variable de control, racismo explícito del país del árbitro, donde observamos una significancia para cada categoría igual al caso del modelo 1. En este sentido, el efecto del color de piel sobre el logit de las odds de recibir una tarjeta roja se mantiene aún después de la inclusión de las dos variables de control. Sin embargo, al incorporar el efecto interacción, se observa que el efecto de todas las variables pierde significancia, lo que indica que el efecto de la variable de interés no estaría moderado por esta variable.

No obstante, nuestra pregunta de interés es ¿tiene el color de piel de los jugadores un efecto sobre la probabilidad de obtener una tarjeta roja? Sin embargo, en los modelos logit, hay un efecto marginal de la variable para cada individuo. Vale decir, los efectos marginales son esencialmente *heterogéneos*. En vista de la generalidad de nuestra pregunta, para testear el efecto marginal del color de piel sobre la probabilidad de tener una tarjeta roja, se estimará un *Average Marginal Effects (AME)*, que corresponde al efecto marginal promedio (en muestra), a partir del modelo numero 3 (sin efecto interacción, por las razones esgrimidas arriba).

En R,

```
summary(marginal_effects(modelo_3))[4,c(2,3,4,5)]

## dydx_rater10.25 dydx_rater10.5 dydx_rater10.75 dydx_rater11
## Mean :0.002306 Mean :0.001903 Mean :0.002946 Mean :0.003481
```

En vista de esto, observamos que el efecto marginal promedio de cada categoría de la variable color de piel es positiva respecto a la variable de referencia. Esto quiere decir que todos los jugadores que tienen piel más oscura que quienes tienen la piel más clara (0), tienen más probabilidad de recibir una tarjeta roja. Ahora bien, esta probabilidad, en promedio, aumenta más para los jugadores que tienen la piel más oscura (1), y menos para los que tienen la piel ni clara ni oscura (0.5).

No obstante, no sabemos si estos efectos son o no significativos. Para evaluar esto, se calculará un intervalo de confianza (IC) al 95% para los *Average Marginal Effect* de color de piel sobre la probabilidad de recibir una tarjeta roja mediante el método Bootstrap.

En R,

```
# Dado que el comando return es terrible, se calculan cuatro bootstrap, uno para el coeficiente de cada c
# ategoría. Se hizo n=50 porque el pc no aguanta.

#Color 25
boots_ef_25 <- function(x) {
```

```

data_aux <- sample_n(data_redcards,size=nrow(data_redcards),replace=TRUE)
logit_aux <- glm(red ~ rater1+pos+meanExp, family=binomial(link="logit"), data=data_aux)
beta_25 <- logit_aux$coefficients[2]
p_hat_aux <- predict(logit_aux, type = "response")
me_rater_25 <- beta_25*p_hat_aux*(1-p_hat_aux)
return(ame_rater_25 = mean(me_rater_25))
}
# Iterar función y almacenar resultados
nreps =50
ame_rater_25 <- replicate(nreps,boots_ef_25())

```

```

ci_ame_rater_25 <-
  quantile(ame_rater_25, p=c(0.025,0.975))

```

#Color 50

```

boots_ef_50 <- function(x) {
  data_aux <- sample_n(data_redcards,size=nrow(data_redcards),replace=TRUE)
  logit_aux <- glm(red ~ rater1+pos+meanExp, family=binomial(link="logit"), data=data_aux)
  beta_50 <- logit_aux$coefficients[3]
  p_hat_aux <- predict(logit_aux, type = "response")
  me_rater_50 <- beta_50*p_hat_aux*(1-p_hat_aux)
  return(ame_rater_50 = mean(me_rater_50))
}

```

```

# Iterar función y almacenar resultados
nreps =50
ame_rater_50 <- replicate(nreps,boots_ef_50())
ci_ame_rater_50 <-
  quantile(ame_rater_50, p=c(0.025,0.975))

```

#Color 75

```

boots_ef_75 <- function(x) {
  data_aux <- sample_n(data_redcards,size=nrow(data_redcards),replace=TRUE)
  logit_aux <- glm(red ~ rater1+pos+meanExp, family=binomial(link="logit"), data=data_aux)
  beta_75 <- logit_aux$coefficients[4]
  p_hat_aux <- predict(logit_aux, type = "response")
  me_rater_75 <- beta_75*p_hat_aux*(1-p_hat_aux)
  return(ame_rater_75 = mean(me_rater_75))
}

```

```

# Iterar función y almacenar resultados
nreps =50
ame_rater_75 <- replicate(nreps,boots_ef_75())
ci_ame_rater_75 <-
  quantile(ame_rater_75, p=c(0.025,0.975))

```

#Color 1

```

boots_ef_1 <- function(x) {

```



```

data_aux <- sample_n(data_redcards,size=nrow(data_redcards),replace=TRUE)
logit_aux <- glm(red ~ rater1+pos+meanExp, family=binomial(link="logit"), data=data_aux)
beta_1 <- logit_aux$coefficients[5]
p_hat_aux <- predict(logit_aux, type = "response")
me_rater_1 <- beta_1*p_hat_aux*(1-p_hat_aux)
return(ame_rater_1 = mean(me_rater_1))
}

# Iterar función y almacenar resultados
nreps =50
ame_rater_1 <- replicate(nreps,boots_ef_1())
ci_ame_rater_1 <-
  quantile(ame_rater_1, p=c(0.025,0.975))

print(paste0("Intervalo de confianza Color 0.25: ", "(",round(ci_ame_rater_25,10)[1],",",
  round(ci_ame_rater_25,10)[2],")" ))

## [1] "Intervalo de confianza Color 0.25: (0.001239334,0.0036911653)"

print(paste0("Intervalo de confianza Color 0.50: ", "(",round(ci_ame_rater_50,10)[1],",",
  round(ci_ame_rater_50,10)[2],")" ))

## [1] "Intervalo de confianza Color 0.50: (-0.0001300209,0.004207034)"

print(paste0("Intervalo de confianza Color 0.75: ", "(",round(ci_ame_rater_75,10)[1],",",
  round(ci_ame_rater_75,10)[2],")" ))

## [1] "Intervalo de confianza Color 0.75: (0.0005117437,0.0057349633)"

print(paste0("Intervalo de confianza Color 1: ", "(",
  round(ci_ame_rater_1,10)[1],",",
  round(ci_ame_rater_1,10)[2],")" ))

## [1] "Intervalo de confianza Color 1: (0.0007622561,0.0058630032)"

```

Se observa que el efecto marginal promedio del color de piel 0.25, a un nivel de confianza del 95%, sobre la probabilidad de recibir tarjeta roja es mayor respecto a la categoría de referencia, ya que no incluye el cero. Por su parte, el intervalo de confianza calculado para el color de piel 0.50 incluye el 0, por lo que el efecto marginal promedio del color de piel 0.5 no es, a un nivel de confianza del 95%, distinto de la categoría de referencia. Respecto a la categoría de color de piel 0.75, el análisis muestra que, a un nivel de confianza del 95%, el IC no incluye el cero. Por ende, el efecto marginal promedio de color de piel 0.75 sobre la probabilidad de recibir una tarjeta roja es mayor que la categoría de referencia, a un nivel de confianza del 95%. Finalmente, respecto a la categoría de color de piel 1, el IC al 95% calculado mediante el método Bootstrap, con n=50 repeticiones, no incluye el valor cero; por lo que a un 95% de confianza, el efecto marginal promedio del color de piel 1 sobre la probabilidad de recibir una tarjeta roja, es mayor que la categoría de referencia.

En función de esto, es posible concluir que existe evidencia estadística a favor de que el color de piel tiene un efecto sobre la probabilidad de recibir una tarjeta roja, controlando por la posición del jugador y el nivel de racismo explícito en el país del árbitro.

6. Análisis complementarios de robustez

Para evaluar la robustez del modelo que ajustamos anteriormente, presentamos a continuación una serie de análisis de los modelos cambiando la variable de interés desde la codificación del primer grupo de evaluadores del color de piel de los jugadores (rater1) al segundo grupo (rater2) y la variable de control la cambiamos de racismo explícito (meanExp) a racismo implícito (meanIAT).

Los modelos a comparar tienen todos la siguiente forma funcional:

- Modelo 1: rojas ~ color piel
- Modelo 2: rojas ~ color de piel + posición
- Modelo 3: rojas ~ color de piel + posición + nivel racismo
- Modelo 4: rojas ~ color de piel*nivel racismo + posición

1. Cambio variable color de piel: rater2 en lugar de rater1; meanExp

```
data_redcards$rater2 <- factor(data_redcards$rater2)

M1.1 <- glm(red~rater2, family=binomial(link="logit"), data=data_redcards)
M2.1 <- glm(red~rater2+pos, family=binomial(link="logit"), data=data_redcards)
M3.1 <- glm(red~rater2+pos+meanExp, family=binomial(link="logit"), data=data_redcards)
M4.1 <- glm(red~rater2*meanExp+pos, family=binomial(link="logit"), data=data_redcards)
screenreg(list(M1.1, M2.1, M3.1, M4.1))

##
## =====
=====
##           Model 1      Model 2      Model 3      Model 4
## -----
## (Intercept)  -4.50 ***  -4.72 ***  -4.64 ***  -4.46 ***
##              (0.05)    (0.08)    (0.10)    (0.14)
## rater20.25    0.17 **   0.18 **   0.18 **   -0.04
##              (0.07)    (0.07)    (0.07)    (0.16)
## rater20.5     0.26 **   0.25 **   0.26 **   -0.15
##              (0.09)    (0.09)    (0.09)    (0.23)
## rater20.75    0.15      0.16      0.16      0.07
##              (0.11)    (0.11)    (0.11)    (0.21)
## rater21       0.22 *    0.27 *    0.27 *    0.05
##              (0.11)    (0.11)    (0.11)    (0.21)
## posDefensa           0.49 ***  0.49 ***  0.49 ***
##                   (0.07)    (0.07)    (0.07)
## posCentrocampista    0.03      0.03      0.03
##                   (0.08)    (0.08)    (0.08)
## posArquero          0.24 *    0.23 *    0.23 *
##                   (0.11)    (0.11)    (0.11)
## meanExp              -0.18    -0.58 *
##                   (0.12)    (0.28)
## rater20.25:meanExp           0.49
##                   (0.33)
## rater20.5:meanExp       0.87 ·
##                   (0.45)
```

```
## rater20.75:meanExp          0.18
##                             (0.43)
## rater21:meanExp            0.51
##                             (0.41)
## -----
## AIC          15618.44    15553.62    15553.35    15556.74
## BIC          15666.73    15630.87    15640.26    15682.28
## Log Likelihood -7804.22    -7768.81    -7767.67    -7765.37
## Deviance      15608.44    15537.62    15535.35    15530.74
## Num. obs.     115457     115457     115457     115457
## =====
## *** p < 0.001; ** p < 0.01; * p < 0.05; · p < 0.1
```

M1.1: Todas las categorías de color de piel tienen significancia, excepto la 0.75. Hay un cambio respecto a rater1, ya que antes la categoría sin significancia era la 0.5.

M2.1: Controlando por la posición del jugador se mantienen las significancias. Cuando se utilizaba la variable rater1, aumentaba la significancia de 1 en relación con el modelo más simple.

M3.1: Controlando nivel de racismo en el país del árbitro (meanExp) se mantienen las significancias respecto a M2.1. Comparando con el modelo con rater1 hay una categoría significativa menos.

M4.1: Agregando el efecto interacción, solo la categoría 0.5 mantiene su significancia al 0.1. Comparando con el modelo que utiliza rater1 hay un cambio, puesto que ahora por lo menos una categoría es significativa.

2. Cambio variable racismo: meanIAT en lugar de meanExp; rater1

```
M1.2 <- glm(red~rater1, family=binomial(link= "logit"), data=data_redcards)
M2.2 <- glm(red~rater1+pos, family=binomial(link= "logit"), data=data_redcards)
M3.2 <- glm(red~rater1+pos+meanIAT, family=binomial(link= "logit"), data=data_redcards)
M4.2 <- glm(red~rater1*meanIAT+pos, family=binomial(link= "logit"), data=data_redcards)
```

```
screenreg(list(M1.2, M2.2, M3.2, M4.2))
```

```
##
## =====
##
##          Model 1    Model 2    Model 3    Model 4
## -----
## (Intercept) -4.48 *** -4.71 *** -4.85 *** -4.60 ***
##              (0.04)   (0.07)   (0.30)   (0.56)
## rater10.25   0.18 **  0.19 **  0.19 **  -0.30
##              (0.06)   (0.06)   (0.06)   (0.77)
## rater10.5    0.17     0.16     0.16 ·   -0.88
##              (0.09)   (0.09)   (0.09)   (1.04)
## rater10.75   0.21 *   0.24 *   0.25 *   0.45
##              (0.10)   (0.10)   (0.10)   (0.91)
## rater11      0.24 *   0.28 **  0.29 **  0.23
```

```
##          (0.11)      (0.11)      (0.11)      (0.90)
## posDefensa      0.49 ***      0.49 ***      0.49 ***
##          (0.07)      (0.07)      (0.07)
## posCentrocampista      0.03      0.03      0.03
##          (0.08)      (0.08)      (0.08)
## posArquero      0.26 *      0.26 *      0.26 *
##          (0.11)      (0.11)      (0.11)
## meanIAT          0.42      -0.30
##          (0.83)      (1.60)
## rater10.25:meanIAT          1.39
##          (2.19)
## rater10.5:meanIAT          2.96
##          (2.96)
## rater10.75:meanIAT          -0.62
##          (2.63)
## rater11:meanIAT          0.15
##          (2.59)
## -----
## AIC          15617.09      15551.63      15553.37      15559.67
## BIC          15665.37      15628.88      15640.28      15685.21
## Log Likelihood -7803.55      -7767.81      -7767.69      -7766.83
## Deviance      15607.09      15535.63      15535.37      15533.67
## Num. obs.      115457      115457      115457      115457
## =====
=====
## *** p < 0.001; ** p < 0.01; * p < 0.05; · p < 0.1
```

M1.2: No aplica. Mismo que Modelo 1 original.

M2.2: No aplica. Mismo que Modelo 2 original.

M3.2: Todas las categorías tienen significancia, la que aumenta para los con piel más oscura (1) en relación con el modelo que considera la variable meanExp.

M4.2: Agregando interacción, ninguna tiene significancia; lo que es igual al modelo con meanExp.

3. Cambio racismo y color de piel: rater2 y meanIAT

```
M1.3 <- glm(red~rater2, family=binomial(link="logit"), data=data_redcards)
M2.3 <- glm(red~rater2+pos, family=binomial(link="logit"), data=data_redcards)
M3.3 <- glm(red~rater2+pos+meanIAT, family=binomial(link="logit"), data=data_redcards)
M4.3 <- glm(red~rater2*meanIAT+pos, family=binomial(link="logit"), data=data_redcards)
```

```
screenreg(list(M1.3, M2.3, M3.3, M4.3))
```

```
##
## =====
=====
##          Model 1      Model 2      Model 3      Model 4
## -----
## (Intercept) -4.50 ***      -4.72 ***      -4.84 ***      -4.01 ***
##          (0.05)      (0.08)      (0.30)      (0.66)
```

```

## rater20.25    0.17 **    0.18 **    0.18 **    -1.06
##              (0.07)    (0.07)    (0.07)    (0.81)
## rater20.5     0.26 **    0.25 **    0.25 **    -1.49
##              (0.09)    (0.09)    (0.09)    (1.14)
## rater20.75    0.15      0.16      0.16      -0.13
##              (0.11)    (0.11)    (0.11)    (0.98)
## rater21       0.22 *     0.27 *     0.28 **    -0.43
##              (0.11)    (0.11)    (0.11)    (0.94)
## posDefensa    0.49 ***    0.49 ***    0.49 ***
##              (0.07)    (0.07)    (0.07)
## posCentrocampista 0.03      0.03      0.03
##              (0.08)    (0.08)    (0.08)
## posArquero    0.24 *     0.24 *     0.24 *
##              (0.11)    (0.11)    (0.11)
## meanIAT              0.34      -2.04
##              (0.83)    (1.90)
## rater20.25:meanIAT              3.56
##              (2.33)
## rater20.5:meanIAT              5.00
##              (3.23)
## rater20.75:meanIAT              0.81
##              (2.84)
## rater21:meanIAT              2.01
##              (2.71)
## -----
## AIC          15618.44    15553.62    15555.45    15559.54
## BIC          15666.73    15630.87    15642.36    15685.08
## Log Likelihood -7804.22    -7768.81    -7768.72    -7766.77
## Deviance     15608.44    15537.62    15537.45    15533.54
## Num. obs.    115457     115457     115457     115457
## =====
=====
## *** p < 0.001; ** p < 0.01; * p < 0.05; · p < 0.1

```

M1.3: No aplica. Mismo que M1.1.

M2.3: No aplica. Mismo que M2.1.

M3.3: Todas las categorías menos 0.75 tienen significancia. Hay una categoría menos que es significativa respecto a M3.1, pero la misma cantidad respecto al Modelo 3 original.

M4.3: Agregando la interacción, ninguna tiene significancia; lo que es igual al Modelo 4 original.

En conclusión, el modelo es robusto frente a cambios en las variables utilizadas para medir color de piel (rater1 vs rater2) y nivel de racismo del país de origen del árbitro (meanExp vs meanIAT), excepto para el modelo M4.1, en que una de las categorías de interacción pasa a ser significativa, y para el modelo M3.1, en que todas las categorías de interés son significativas.